# A / B 两种共享 K/V 方案

同一 YOCO 基座，只改变“前六层的信息如何融合”。

## 共同框架：融合一次，后六层共享

前6层：H1 → H2 → … → H6 → 按 A 或 B 加权融合 → 共享 K* / V*

各层经同一组归一化、K/V投影，得到六对候选记忆。

进入第7层前只做一次。

第7–12层各自生成Q，复用同一份记忆。

$$K_t^* = \sum_{j=1}^{6} \alpha_{t,j} K_{t,j}, \qquad V_t^* = \sum_{j=1}^{6} \alpha_{t,j} V_{t,j}$$

K 和 V 共用一组权重；softmax 在六个来源层之间进行，权重之和为 1。

### A | 全局可学习配比

所有 token 共用一套层权重。

$$\alpha_j = \mathrm{softmax}_j(b)$$

学习六个全局参数 b。
训练时更新配比；配比本身不随当前 token 的输入改变。

新增参数：6

### B | 按 token 内容分配

不同 token 可以有不同层权重。

$$s_{t,j} = \frac{w^\top \mathrm{RMSNorm}(H_{t,j})}{\sqrt{d}} + b_j$$

$$\alpha_{t,j} = \mathrm{softmax}_j(s_{t,\,\cdot})$$

w 是共享打分向量，b 是层偏置。
RMSNorm 无额外可学习参数。
按当前 token 的各层表示生成配比。

新增参数：d + 6 = 774

## 共同约定

初始化：A 的 b=0；B 的 w=0、b=0，两组都从六层等权（1/6）起步。
K 的位置旋转在融合后执行；因果 mask 保留，Q 主路径从第6层输出继续。

符号：t 为 token 位置，j 为来源层（1–6），d=768。Baseline 仅从 H6 生成 K/V。

---

一句话：A 学“全局配比”；B 学“按 token 内容算配比”。